

TP — Audit & cartographie des données

Immobilier × Énergie — Loire-Atlantique (44)

Louis Valette

Alexis Fouquet

Contents

1. Présentation du sujet	1
2. Sources de données	2
3. Dictionnaire de données	3
4. Modèle conceptuel (MCD)	4
5. Modèle logique (MLD)	6
6. Base PostgreSQL	7
7. Cartographie globale	8

1. Présentation du sujet

Contexte

La rénovation énergétique et la valeur des biens immobiliers sont deux enjeux étroitement liés en France : depuis 2021 le Diagnostic de Performance Énergétique (DPE) influence la décision d'achat, tandis que les données de transactions immobilières (DVF) objectivent les prix du marché. Croiser ces deux sources à l'échelle d'un département permet d'observer, sur des données réelles, le lien entre performance énergétique et marché immobilier local.

Problématique

Dans le département de la **Loire-Atlantique (44)**, existe-t-il un écart de prix observable entre les logements performants (étiquettes DPE A/B/C) et les logements énergivores (étiquettes F/G), et comment cet écart varie-t-il selon les communes ?

Objectif

Construire, à partir de trois jeux de données publics réels, une base de données PostgreSQL structurée permettant de rapprocher transactions immobilières et diagnostics énergétiques à l'échelle communale, et de répondre à la problématique par des requêtes d'analyse (prix moyen au m² par étiquette DPE, par commune).

Sujet retenu

Immobilier × Énergie — croisement de deux sujets de la liste plutôt qu'un seul, pour donner du sens à l'analyse.

Périmètre

Département : Loire-Atlantique (44), 207 communes — équilibre entre pôle urbain (Nantes, Saint-Nazaire) et zones rurales/littorales, avec une volumétrie maîtrisable pour un TP.

2. Sources de données

Trois sources réelles, toutes restreintes au département de la Loire-Atlantique (44).

1. DVF — Demandes de valeurs foncières (géolocalisée)

Champ	Valeur
Nom de la source	DVF géolocalisée (geo-dvf)
Organisation / origine	DGFiP, republiée par Etalab
URL	https://files.data.gouv.fr/geo-dvf/latest/csv/2025/departements/44.csv.gz
Format	CSV compressé (.csv.gz)
Nature	Structurée (une ligne = une disposition de mutation)
Description	Transactions immobilières réelles (ventes de maisons, appartements, terrains, locaux) sur le département 44, géolocalisées.

2. DPE Logements existants (depuis juillet 2021)

Champ	Valeur
Nom de la source	DPE Logements existants
Organisation / origine	ADEME — Observatoire DPE-Audit
URL	https://data.ademe.fr/data-fair/api/v1/datasets/dpe03existant/lines
Format	JSON via API (data-fair), converti en CSV
Nature	Structurée (un enregistrement = un diagnostic)
Description	Diagnostics de performance énergétique individuels (par logement) : étiquette énergie, étiquette GES, année de construction, surface habitable, type de bâtiment, adresse. Filtrage sur le département via <code>qs=code_departement_ban:44</code> .

3. Code Officiel Géographique (COG) — communes

Champ	Valeur
Nom de la source	Liste des communes de France (COG)
Organisation / origine	INSEE, republiée via data.gouv.fr
URL	https://www.data.gouv.fr/datasets/communes-et-villes-de-france-en-csv-excel-json-parquet-et-feather
Format	CSV

Champ	Valeur
Nature	Structurée (une ligne = une commune)
Description	Table de référence géographique : code INSEE, nom, codes postaux, département, région, EPCI, population.

Les trois sources sont reliées par le code INSEE de la commune (code_commune en DVF, code_insee_ban en DPE, code_insee en COG).

3. Dictionnaire de données

Analyse des principales colonnes retenues pour chaque source, restreintes au département 44. Seules les colonnes utiles au modèle sont détaillées (les fichiers sources bruts contiennent davantage de colonnes — 38 pour DVF, 230 pour le DPE).

DVF — transactions immobilières

Champ	Description	Type	Exemple
id_mutation	Identifiant de la mutation (peut se répéter sur plusieurs lignes si plusieurs lots/parcelles)	varchar	2025-563764
date_mutation	Date de la transaction	date	2025-01-06
nature_mutation	Type de mutation	varchar	Vente
valeur_fonciere	Prix de la transaction en euros	numeric	175000
code_postal	Code postal du bien	char(5)	44520
code_commune	Code INSEE de la commune	char(5)	44099
nom_commune	Nom de la commune	varchar	Moisdon-la-Rivière
code_departement	Code département	char(2)	44
id_parcelle	Identifiant cadastral de la parcelle	varchar	44099000AC0006
code_type_local	Code du type de local	integer	1
type_local	Type de bien	varchar	Maison, Appartement
surface_reelle_bati	Surface bâtie en m ²	numeric	98
nombre_pieces_principales	Nombre de pièces	integer	5
surface_terrain	Surface du terrain en m ²	numeric	945
longitude / latitude	Coordonnées géographiques	numeric	-1.37258 / 47.624643

DPE — diagnostics de performance énergétique

Champ	Description	Type	Exemple
numero_dpe	Identifiant unique du diagnostic	varchar	2644E0039039K
code_insee_ban	Code INSEE de la commune (géocodage BAN)	char(5)	44109
code_postal_ban	Code postal (géocodage BAN)	char(5)	44300

Champ	Description	Type	Exemple
date_etablissement_dpe	Date de réalisation du diagnostic	date	2026-01-07
etiquette_dpe	Étiquette énergie (A à G)	char(1)	C
etiquette_ges	Étiquette gaz à effet de serre (A à G)	char(1)	C
annee_construction	Année de construction du bâtiment	integer	2020
periode_construction	Tranche de période de construction	varchar	2013-2021
type_batiment	Type de bâtiment	varchar	appartement, maison
surface_habitable_logement	Surface habitable en m²	numeric	64.3
adresse_ban	Adresse complète normalisée (BAN)	varchar	20 Route de Carquefou 44300 Nantes

COG — communes (référentiel géographique)

Champ	Description	Type	Exemple
code_insee	Code INSEE de la commune (clé primaire)	char(5)	44109
nom_standard	Nom usuel de la commune	varchar	Nantes
dep_code	Code département	char(2)	44
dep_nom	Nom du département	varchar	Loire-Atlantique
reg_code	Code région	char(2)	52
reg_nom	Nom de la région	varchar	Pays de la Loire
code_postal	Code postal principal	char(5)	44000
epci_code / epci_nom	Identifiant / nom de l'intercommunalité	varchar	244400404 / Nantes Métropole

4. Modèle conceptuel (MCD)

Entités et attributs

COMMUNE

Table de référence géographique, issue du COG, restreinte au département 44 (207 communes).

- code_insee (identifiant)
- nom_commune
- code_postal
- epci_code, epci_nom
- dep_code, dep_nom
- reg_code, reg_nom

TRANSACTION

Une transaction immobilière (mutation DVF), rattachée à une commune.

- id_transaction (identifiant)
- id_mutation

- date_mutation
- nature_mutation
- valeur_fonciere
- type_local
- surface_reelle_bati
- nombre_pieces_principales
- surface_terrain
- longitude, latitude

DIAGNOSTIC_DPE

Un diagnostic de performance énergétique, rattaché à une commune.

- numero_dpe (identifiant)
- date_etablissement_dpe
- etiquette_dpe
- etiquette_ges
- annee_construction
- periode_construction
- type_batiment
- surface_habitable_logement
- adresse

Relations et cardinalités

COMMUNE 1 — N TRANSACTION

COMMUNE 1 — N DIAGNOSTIC_DPE

- Une **commune** est concernée par **0 à N transactions** ; une **transaction** appartient à **exactement 1 commune**.
- Une **commune** est concernée par **0 à N diagnostics DPE** ; un **diagnostic** porte sur **exactement 1 commune**.

Justification des choix

- **Pas de lien direct TRANSACTION ↔ DIAGNOSTIC_DPE** : les deux sources n'ont pas de clé fiable au niveau du logement (DVF identifie une parcelle, le DPE une adresse géocodée). Le rapprochement se fait donc **au niveau commune**, seule clé fiable aux deux sources, suffisante pour répondre à la problématique.
- **Entité COMMUNE séparée** plutôt que dupliquer les infos géographiques dans chaque table : évite la redondance et garantit une source de vérité unique (le COG), en contrainte d'intégrité référentielle sur les deux autres tables.

Diagramme (dbdiagram.io)

Schéma DBML prêt à coller sur dbdiagram.io :

```
Table commune {
  code_insee char(5) [pk]
  nom_commune varchar(100)
  code_postal char(5)
  epci_code varchar(15)
  epci_nom varchar(150)
  dep_code char(2)
  dep_nom varchar(50)
```

```

    reg_code char(2)
    reg_nom varchar(50)
}

Table transaction_dvf {
    id_transaction bigint [pk, increment]
    id_mutation varchar(20)
    date_mutation date
    nature_mutation varchar(50)
    valeur_fonciere numeric(12,2)
    code_insee char(5) [ref: > commune.code_insee]
    type_local varchar(50)
    surface_reelle_bati numeric(8,2)
    nombre_pieces_principales smallint
    surface_terrain numeric(10,2)
    longitude numeric(9,6)
    latitude numeric(9,6)
}

Table diagnostic_dpe {
    numero_dpe varchar(20) [pk]
    code_insee char(5) [ref: > commune.code_insee]
    date_etablissement_dpe date
    etiquette_dpe char(1)
    etiquette_ges char(1)
    annee_construction integer
    periode_construction varchar(20)
    type_batiment varchar(30)
    surface_habitable_logement numeric(8,2)
    adresse varchar(255)
}

```

5. Modèle logique (MLD)

Traduction du modèle conceptuel (04_modele_conceptuel.md) en tables relationnelles. Script de création correspondant : sql/01_create_tables.sql.

commune

Colonne	Type	Contrainte
code_insee	CHAR(5)	PK
nom_commune	VARCHAR(100)	NOT NULL
code_postal	CHAR(5)	
epci_code	VARCHAR(15)	
epci_nom	VARCHAR(150)	
dep_code	CHAR(2)	NOT NULL
dep_nom	VARCHAR(50)	
reg_code	CHAR(2)	
reg_nom	VARCHAR(50)	

transaction_dvf

Colonne	Type	Contrainte
id_transaction	BIGSERIAL	PK
id_mutation	VARCHAR(20)	NOT NULL
date_mutation	DATE	NOT NULL
nature_mutation	VARCHAR(50)	
valeur_fonciere	NUMERIC(12,2)	NOT NULL, CHECK ≥ 0
code_insee	CHAR(5)	FK → commune(code_insee), NOT NULL
type_local	VARCHAR(50)	
surface_reelle_bati	NUMERIC(8,2)	CHECK ≥ 0
nombre_pieces_principales	SMALLINT	
surface_terrain	NUMERIC(10,2)	CHECK ≥ 0
longitude	NUMERIC(9,6)	
latitude	NUMERIC(9,6)	

Notation : transaction_dvf porte une clé primaire technique (id_transaction) car une même mutation DVF (id_mutation) peut apparaître sur plusieurs lignes du fichier source (un lot/parcelle par ligne) — id_mutation est donc conservé comme attribut, pas comme clé.

diagnostic_dpe

Colonne	Type	Contrainte
numero_dpe	VARCHAR(20)	PK
code_insee	CHAR(5)	FK → commune(code_insee), NOT NULL
date_etablissement_dpe	DATE	
etiquette_dpe	CHAR(1)	CHECK IN (A..G)
etiquette_ges	CHAR(1)	CHECK IN (A..G)
annee_construction	INTEGER	
periode_construction	VARCHAR(20)	
type_batiment	VARCHAR(30)	
surface_habitable_logement	NUMERIC(8,2)	CHECK ≥ 0
adresse	VARCHAR(255)	

Relations (clés étrangères)

- transaction_dvf.code_insee → commune.code_insee
- diagnostic_dpe.code_insee → commune.code_insee

Index

- commune : PK sur code_insee (index automatique)
- transaction_dvf : index sur code_insee (jointures), index sur date_mutation
- diagnostic_dpe : index sur code_insee (jointures), index sur etiquette_dpe

6. Base PostgreSQL

Scripts

Script	Rôle
sql/01_create_tables.sql	Création des 3 tables, contraintes, index
sql/02_insert_test_data.sql	Quelques données de test manuelles (3 communes, 3 transactions, 3 diagnostics)
sql/03_import_donnees_reelles.sql	Import des données réelles nettoyées du département 44 (data/staging/)
sql/04_requetes_verification.sql	Contrôle des relations (comptages, orphelins)
sql/05_requetes_analyse.sql	Requêtes répondant à la problématique du TP

Comment reproduire

```
docker run -d --name tp_audit_44_pg -e POSTGRES_PASSWORD=postgres \
  -e POSTGRES_DB=audit_immo_energie_44 -p 5433:5432 postgres:16

psql -h localhost -p 5433 -U postgres -d audit_immo_energie_44 -f sql/01_create_tables.sql
psql -h localhost -p 5433 -U postgres -d audit_immo_energie_44 -f sql/02_insert_test_data.sql # données de test
# ou, pour les données réelles (depuis la racine du projet) :
psql -h localhost -p 5433 -U postgres -d audit_immo_energie_44 -f sql/03_import_donnees_reelles.sql
```

Résultats de la vérification

Base testée avec import complet des trois sources nettoyées :

Table	Lignes importées
commune	207
transaction_dvf	79 315
diagnostic_dpe	351 959

0 transaction orpheline, 0 diagnostic orphelin : toutes les clés étrangères sont valides, les contraintes CHECK passent sans erreur.

Résultat des requêtes d'analyse

Le prix moyen au m² est calculé au niveau de la mutation, pas de la ligne brute, pour éviter un biais des mutations DVF à plusieurs lots (valeur_fonciere répétée sur chaque lot) — cf. commentaire en tête de [sql/05_requetes_analyse.sql](#).

Le croisement prix moyen au m² / part de logements F-G par commune fait apparaître une tendance : les communes les plus chères sont les pôles littoraux (La Baule-Escoublac 6 536 €/m², Pornichet 5 647 €/m²) et Nantes (3 778 €/m²), avec une part de logements F-G plus faible que les communes rurales les moins chères (Juigné-des-Moutiers 892 €/m² et 35,7 % de F-G, Soulvache 1 015 €/m² et 25,7 %). À nuancer : faibles effectifs sur les petites communes rurales, corrélation ≠ causalité.

7. Cartographie globale

Vue d'ensemble du cheminement, des données brutes à la base PostgreSQL. La structure (dictionnaire, MCD, MLD) est établie en premier à partir des sources réelles — le nettoyage n'intervient qu'ensuite, pour adapter les données à cette structure.




Figure 1: Cartographie globale du cheminement

Lecture du schéma

1. **Trois sources hétérogènes** sont ramenées à un périmètre commun : le département 44.
2. **Dictionnaire + modélisation** (MCD → MLD) sont établis d'abord, à partir des colonnes réelles. Architecture "en étoile" : deux tables de faits reliées uniquement par la dimension commune (justification en 04_modele_conceptuel.md).
3. **Audit qualité et nettoyage** adaptent ensuite les données réelles à ce modèle.
4. **La base PostgreSQL** matérialise le modèle, testée de bout en bout (0 ligne orpheline).
5. **L'analyse** répond à la problématique à l'échelle communale.