

TP3 — Audit qualité & nettoyage des données

Prolongement du TP1/TP2 — Immobilier × Énergie, Loire-Atlantique (44)

Louis Valette

Alexis Fouquet

Ruben Cofflard

Contents

1. Périmètre	1
2. Matrice de contrôles qualité	1
3. Méthodologie	1
4. Anomalies et corrections	2
5. Recontrôle	2

1. Périmètre

Audit qualité sur les 4 tables du schéma cible (TP1 : commune, transaction_dvf, diagnostic_dpe ; TP2 : diagnostic_dpe_flux). Le schéma cible, vérifié à cette occasion, est tenu à jour dans [docs/05_modele_logique.md](#) (diagnostic_dpe_flux y manquait, ajoutée avant l’audit).

2. Matrice de contrôles qualité

Ciblée sur ce que les contraintes SQL actives (PK, FK, CHECK) ne couvrent pas déjà.

Dimension	Contrôle
Complétude	Taux de NULL sur les champs significatifs (annee_construction, surface_habitable_logement, surface_reelle_bati...)
Unicité	Cohérence des doublons attendus (multi-lots DVF) ; risque de faux positif sur “adresse + date”
Validité	Valeurs hors bornes plausibles (pièces à 0, surfaces aberrantes, années impossibles)
Cohérence	Prix au m² extrêmes, agrégés par mutation
Intégrité référentielle	Orphelins sur les 3 relations vers commune

3. Méthodologie

Script unique, [sql/07_audit_qualite.sql](#), exécuté à l’identique avant et après [sql/08_nettoyage.sql](#).

Deux pièges méthodologiques rencontrés, qui ont changé la façon dont les contrôles sont écrits :

- **Prix au m² non calculable ligne par ligne** : une mutation DVF à plusieurs lots répète la même valeur_ fonciere sur chaque ligne — diviser par la surface d'un seul lot donne des prix au m² absurdes (jusqu'à 566 250 €/m² avant correction de la méthode). Agrégation par id_mutation requise (même logique qu'en TP1).
- **"Même adresse + même date" n'est pas un doublon** : un immeuble collectif peut compter plusieurs centaines de logements diagnostiqués la même campagne (jusqu'à 869 observés) — chacun avec un numero_dpe distinct et légitime.

4. Anomalies et corrections

#	Anomalie	Avant	Après	Décision
1	nombre_pieces_principales = 0 sur logement habitable	46	0	Substitution → NULL
2	surface_habitable_logement > 400 m ² pour un appartement	34	0	Substitution → NULL
3	annee_construction < 1700	34	34	Aucune correction (bâti ancien réel, rien ne prouve l'erreur)
4	Mutations à prix/m ² > 15 000 €/m ² (agrégées)	22	22	Aucune correction (valeurs individuelles plausibles, ratio non interprétable à ce niveau)
5	annee_construction NULL	119 644 (34 %)	inchangé	Aucune imputation (periode_construction, complet à 100 %, sert de substitut)
6	NULL structurels transaction_dvf (mutations sans bâti)	52 589 / 31 229	inchangé	Aucune correction (absence légitime, 0 cas sur Maison/Appartement)
7	Orphelins référentiels	0	0	Contrôle confirmatoire (déjà garanti par les FK)

Deux corrections réelles (46 + 34 lignes), cinq décisions documentées de ne pas corriger — pour ne pas laisser d'anomalies non traitées en silence.

5. Recontrôle

Script d'audit ré-exécuté à l'identique après nettoyage, sur la base réelle (351 959 diagnostics, 79 315 transactions, 207 communes). Les deux anomalies corrigées passent à 0 ; les cinq décisions "aucune correction" restent inchangées à l'identique, confirmant que les corrections appliquées sont ciblées et sans effet de bord.

Comment reproduire

```
docker exec -i tp_audit_44_pg psql -U postgres -d audit_immo_energie_44 < sql/07_audit_qualite.sql # avant
docker exec -i tp_audit_44_pg psql -U postgres -d audit_immo_energie_44 < sql/08_nettoyage.sql      # corrections
docker exec -i tp_audit_44_pg psql -U postgres -d audit_immo_energie_44 < sql/07_audit_qualite.sql # après
```