

Audit qualité & nettoyage des données

Immobilier × Énergie en Loire-Atlantique (44)

Ruben Cofflard
Alexis Fouquet
Louis Valette

Soutenance TP3 - NEXA

En Loire-Atlantique, les logements énergivores (F-G) se vendent-ils moins cher que les logements performants (A-B-C) ? Et comment cet écart varie-t-il selon les communes ?

Pourquoi ?

Depuis 2021, le DPE pèse sur la décision d'achat.

Où ?

Département 44 : 207 communes, urbaines, littorales et rurales.

Comment ?

Croiser prix de vente et diagnostics dans une base SQL.

Trois sources ouvertes, une base PostgreSQL

Toutes restreintes au département 44 et reliées par un seul identifiant : le code INSEE de la commune.

207

communes
(COG INSEE)

79 315

transactions
(DVF)

351 959

diagnostics
(DPE ADEME)

~350 k

DPE en flux
(pipeline TP2)


Trois TP, trois étapes




Une seule base, enrichie à chaque étape : les résultats du TP1 ont été revérifiés à chaque TP.

Le schéma cible : un modèle en étoile

Vérifié en TP3 : la table du TP2 manquait dans le modèle logique, ajoutée.



Préparer, mesurer, corriger, vérifier



Les communes chères ont moins de passoires

Les plus chères

Commune	Prix moyen
La Baule-Escoublac	6 536 €/m ²
Pornichet	5 647 €/m ²
Nantes	3 778 €/m ²


Littoral et métropole : part de F-G plus faible.

Les moins chères

Commune	Prix	F-G
Juigné-des-Moutiers	892 €/m ²	35,7 %
Soulvache	1 015 €/m ²	25,7 %


Communes rurales : beaucoup plus de passoires.

Part de passoires (F-G) selon l'époque de construction



3 · RÉSULTATS — TABLEAU DE BORD METABASE

Le parc du 44 est majoritairement en C et D



75 %

des DPE classés C (45 %) ou D (30 %)

4,5 %

de logements classés F

350 182

DPE traités par le flux temps réel

Des données globalement fiables

6

anomalies analysées

2

corrigées
(80 lignes)

4

conservées,
décision justifiée

0

ligne orpheline
(3 relations)

Audit mené sur 4 tables : 207 communes, 79 315 transactions DVF, 351 959 DPE et le flux temps réel du TP2.

Six anomalies, classées par importance

Anomalie	Volume	Part	Importance	Décision
0 pièce sur maison / appartement	46	0,2 %	Moyenne	Corrigé
Appartement de plus de 400 m ²	34	< 0,1 %	Moyenne	Corrigé
Prix > 15 000 €/m ² (par vente)	22	< 0,1 %	Moyenne	Exclu des moyennes
Année de construction < 1700	34	< 0,1 %	Faible	Conservé
Année de construction manquante	119 644	34 %	Forte	Pas d'imputation
Surface bâtie DVF manquante	52 589	66 %	Nulle	Normal

Deux fausses alertes identifiées

566 250 €/m²

Prix au m² calculé ligne par ligne

Une vente à plusieurs lots répète le prix total sur chaque ligne. Solution : regrouper par **id_mutation** avant de diviser.

869 DPE

« Même adresse + même date »

Un immeuble compte des centaines de logements diagnostiqués le même jour. Ce ne sont pas des doublons : chaque **numero_dpe** est distinct.

Deux corrections : remplacer le faux par NULL

1 · Logement à 0 pièce

```
UPDATE transaction_dvf  
SET nombre_pieces_principales = NULL  
WHERE nombre_pieces_principales = 0  
AND type_local IN ('Maison', 'Appartement');
```

0 pièce est impossible pour un logement habitable. Les dépendances à 0 pièce restent intactes.

2 · Appartement > 400 m²

```
UPDATE diagnostic_dpe  
SET surface_habitable_logement = NULL  
WHERE surface_habitable_logement > 400  
AND type_batiment = 'appartement';
```

Sans doute la surface de tout l'immeuble. Même correction répercutée sur la table flux.

Pourquoi NULL ? On ne connaît pas la vraie valeur : **mieux vaut une absence qu'une valeur inventée.**

Ne pas corriger, c'est aussi une décision

Année < 1700

Le bâti ancien existe bel et bien. Rare ne veut pas dire faux.

Prix > 15 000 €/m²

Chaque valeur brute est plausible. On les exclut des moyennes, sans les modifier.

34 % d'années manquantes

Imputer autant de valeurs créerait du biais. La période de construction, complète à 100 %, sert de substitut.

Surfaces DVF vides

Terrains nus et dépendances : l'absence est normale. On filtre dans la requête, pas dans la table.

Avant / après : ciblé, sans effet de bord

Contrôle	Avant	Après
Logements à 0 pièce	46	0
Appartements > 400 m ²	34	0
Année < 1700	34	34
Ventes > 15 000 €/m ²	22	22
Année manquante	119 644	119 644
Orphelins (3 relations)	0	0

80

lignes modifiées, sur plus de
430 000

Tout le reste est identique : les
corrections ne touchent que leur cible.

4 · CONCLUSION

Une réponse fondée sur des données vérifiées

Problématique

Oui, un lien apparaît : prix élevés et peu de passoires vont ensemble, surtout littoral contre rural.

Audit qualité

Données fiables : 80 lignes corrigées, chaque décision justifiée, 0 orphelin.

Et ensuite

Intégrer ces contrôles au pipeline Spark, pour nettoyer le flux en continu.

Merci. Des questions ?